

PROYECTO FINAL APRENDIZAJE DE MÁQUINA Y ANÁLISIS DE DATOS

Departamento de Electrónica y Ciencias de la Computación – DECC | PUJC

Asignatura: Aprendizaje Automático y Análisis de Datos

Profesor: Felipe Palta, M.Sc. felipe.palta@javerianacali.edu.co

Enunciado:

Durante el desarrollo de la asignatura se han estudiado los fundamentos necesarios para construir un sistema completo de clasificación usando Machine Learning clásico. Entre los temas abordados se encuentran el análisis exploratorio de datos, la división de datos en entrenamiento y prueba, la evaluación mediante matriz de confusión y métricas de clasificación, el uso de modelos supervisados, la reducción de dimensionalidad con PCA, la validación cruzada y la construcción de flujos de trabajo mediante Pipeline en Python.

Adicionalmente, se realizó una introducción al procesamiento digital de imágenes, donde se estudiaron conceptos como imagen monocromática, imagen RGB, histogramas, umbralización, segmentación básica y extracción inicial de información visual. Estos conceptos serán fundamentales para el desarrollo del presente proyecto.

El objetivo del proyecto es que cada grupo construya un sistema de clasificación de imágenes de principio a fin. Para ello, cada grupo deberá seleccionar un dataset público de imágenes y desarrollar una solución basada en extracción manual o ingenieril de características, evitando depender directamente de modelos de deep learning o redes neuronales convolucionales.

Cada grupo deberá escoger un dataset diferente de los propuestos por el docente. Se recomienda que el dataset tenga al menos dos clases y que permita formular un problema de clasificación claro, ya sea binario o multiclase.

El proyecto no consiste únicamente en entrenar modelos, sino en diseñar una representación numérica adecuada de las imágenes. Por esta razón, una de las partes más importante del trabajo será la extracción de características visuales. Cada grupo deberá analizar qué información de la imagen puede ser útil para diferenciar las clases: color, intensidad, textura, forma, bordes, regiones, histogramas, descriptores geométricos u otras características investigadas por el grupo que permitan generar un dataset de entrenamiento y así poder entrenar los modelos de aprendizaje de máquina.

Nota 1:

- Los modelos mínimos que deberán ser evaluados son: Perceptrón, Adaline o una aproximación equivalente, Regresión Logística, SVM con kernel lineal, SVM con kernel polinómico, SVM con kernel RBF, KNN, Árbol de Decisión y Bosque Aleatorio.
- Además, cada grupo deberá aplicar PCA para analizar la reducción de dimensionalidad y estudiar si esta técnica mejora, empeora o mantiene el desempeño de los modelos. También se deberá usar validación cruzada y Pipeline de sklearn para organizar correctamente las fases de escalamiento, reducción de dimensionalidad y clasificación.
- La evaluación del sistema deberá realizarse mediante matriz de confusión, accuracy, precision, recall, F1-score y análisis por clase. No será suficiente reportar un único valor de exactitud; se deberá analizar qué clases se clasifican mejor, cuáles generan más confusión y qué tipo de imágenes producen errores.

Preguntas:

1. Comprensión del problema y del dataset

Cada grupo debe responder:

1. ¿Cuál es el problema de clasificación que plantea el dataset asignado?
2. ¿El problema es binario o multiclase?
3. ¿Cuántas clases hay y qué representa visualmente cada clase?
4. ¿Las clases parecen visualmente separables a simple vista? Justifique con ejemplos.
5. ¿Qué dificultades visuales podrían afectar la clasificación?
Por ejemplo: ruido, iluminación, rotación, escala, fondo, similitud entre clases, baja resolución o desbalance.

2. EDA de alta profundidad

Cada grupo debe realizar un EDA que incluya mínimo:

1. Conteo de imágenes por clase.
2. Distribución porcentual de clases.

3. Tamaños originales de las imágenes.
4. Número de canales: monocromático, RGB u otro.
5. Visualización de muestras representativas por clase.
6. Histogramas de intensidad o histogramas RGB/HSV por clase.
7. Análisis de contraste, brillo, textura y bordes.
8. Detección de clases visualmente parecidas.
9. Identificación de posibles outliers visuales.
10. Discusión sobre si el dataset está balanceado o no.

3. Preprocesamiento digital de imágenes

Deben justificar y aplicar un flujo de preprocesamiento, por ejemplo:

1. Redimensionamiento estándar de imágenes.
2. Conversión a escala de grises cuando tenga sentido.
3. Normalización de intensidades.
4. Suavizado o filtrado si aplica.
5. Segmentación simple si aplica.
6. Umbralización de Otsu cuando tenga sentido.
7. Extracción de región de interés si el objeto principal está sobre fondo simple.
8. Comparación entre usar imagen completa y usar imagen segmentada.

La idea es que el grupo no haga todo mecánicamente. Debe justificar **por qué cada transformación ayuda o no ayuda** al problema.

4. Extracción de características visuales

Este debe ser el corazón del proyecto.

Cada grupo debe construir al menos **tres familias de características**:

A. Características de intensidad/color

Ejemplos:

- Media, desviación estándar, mínimo, máximo.
- Histogramas de gris.
- Histogramas RGB.
- Histogramas HSV.
- Momentos estadísticos por canal.
- Proporción de píxeles claros/oscuros.
- Dominancia de color.

B. Características de forma/bordes

Ejemplos:

- Área del objeto segmentado.
- Perímetro.
- Circularidad.
- Relación alto/ancho.
- Momentos de Hu.
- Bordes con Canny.
- Proporción de píxeles de borde.
- Descriptores por zonas de la imagen.

C. Características de textura

Ejemplos:

- LBP.
- GLCM.
- Contraste.
- Homogeneidad.
- Energía.
- Correlación.
- Entropía.

- HOG.

En general, puede investigar y justificar el uso de cualquier técnica para extracción de características.

5. Construcción del dataset tabular final

Cada grupo debe entregar un dataframe final donde:

1. Cada fila represente una imagen.
2. Cada columna represente una característica extraída.
3. Exista una columna objetivo y.
4. Se documenten claramente todas las variables.
5. Se indique qué características son de color, textura, forma o intensidad.
6. Se analice correlación entre características.
7. Se detecten características redundantes o poco informativas.

6. División train/test

Deben usar una división adecuada:

1. train_test_split.
2. División estratificada.
3. Semilla fija para reproducibilidad.
4. Justificación del porcentaje usado.
5. Verificación de que la proporción de clases se conserve en train y test.

7. Modelos obligatorios

Cada grupo debe entrenar y comparar al menos:

1. Perceptrón.
2. Adaline o una aproximación equivalente implementada por el grupo.
3. Regresión logística.
4. SVM lineal.
5. SVM polinómico.
6. SVM RBF.
7. KNN.
8. Árbol de decisión.

9. Bosque aleatorio.

No basta con mostrar accuracy. Deben comparar comportamiento, sensibilidad al escalamiento, costo computacional, sobreajuste y desempeño por clase.

8. PCA y reducción de dimensionalidad

Cada grupo debe responder:

1. ¿Cuántas características originales se tenían?
2. ¿Cuánta varianza explican los primeros componentes principales?
3. ¿Cuántos componentes son necesarios para explicar 90 %, 95 % o 99 % de la varianza?
4. ¿PCA mejora, empeora o mantiene el desempeño?
5. ¿Qué modelos se benefician más de PCA?
6. ¿Qué modelos pierden interpretabilidad con PCA?
7. Visualizar las clases usando PC1 vs PC2 y, si es posible, PC1 vs PC2 vs PC3.

9. Validación cruzada y búsqueda de hiperparámetros

Cada grupo debe usar:

1. cross_val_score o cross_validate.
2. StratifiedKFold.
3. GridSearchCV o RandomizedSearchCV.
4. Comparación entre resultado de validación cruzada y resultado final en test.
5. Discusión sobre varianza del modelo.

10. Uso obligatorio de Pipeline

Cada grupo debe implementar al menos dos pipelines:

- a. Uno sin PCA
- b. Otro con PCA

11. Evaluación final

La evaluación debe incluir:

1. Matriz de confusión.
2. Accuracy.

3. Precision.
4. Recall.
5. F1-score.
6. Análisis por clase.
7. Identificación de clases más confundidas.
8. Discusión visual de errores: mostrar imágenes mal clasificadas.
9. Conclusión técnica: qué características ayudaron más y cuáles no.

12 . Opción de rechazo: Al mejor modelo obtenido de todos durante el desarrollo de todo el trabajo deberá de aplicarle la técnica de la OPCIÓN DE RECHAZO y comparar el objeto del resultado vs el modelo sin opción de rechazo basado en un análisis crítico del caso.

Entregables:

1. Notebook completo en Google Colab.
2. Carpeta con funciones .py reutilizables.
3. Dataset tabular final de características en .csv.
4. Presentación corta de resultados.
5. Matriz de confusión final.
6. Tabla comparativa de modelos.
7. Evidencia visual de imágenes correctamente e incorrectamente clasificadas.